

RAPTOR Patent V4-mini

Review-sheet gold answer 기반 pilot reproduction. V3 retrieval/reader 결과를 재사용하고 Answer F1 중심으로 재평가했습니다.

What Changed From V3

V3는 LLM-generated pseudo-gold와 GPT judge 중심이었고, V4-mini는 review sheet의 gold_reference_answer 기준 Answer F1을 메인 지표로 사용합니다.

QA

10

global 5, local 5

Tree

V3 reused

Main metric

Answer F1

Accuracy

Aux only

Core Metrics

Method	Answer F1	Answer Recall	Source Recall
bm25_without_raptor	0.250	0.297	0.228
bm25_with_raptor	0.405	0.505	0.980
dense_bge_m3_without_raptor	0.430	0.508	0.750
dense_bge_m3_with_raptor	0.428	0.535	1.000

Best Answer F1: dense_bge_m3_without_raptor (0.430).

Global / Local Split

Type	Method	Answer F1
global	bm25_without_raptor	0.289
global	bm25_with_raptor	0.399
global	dense_bge_m3_without_raptor	0.292
global	dense_bge_m3_with_raptor	0.393
local	bm25_without_raptor	0.211
local	bm25_with_raptor	0.411
local	dense_bge_m3_without_raptor	0.568
local	dense_bge_m3_with_raptor	0.463

With / Without RAPTOR Delta

Retriever	Answer F1 Δ	Answer Recall Δ	Source Recall Δ
BM25	+0.155	+0.207	+0.752
Dense BGE-M3	-0.002	+0.027	+0.250

Interpretation

V4-mini는 제출용 benchmark가 아니라 재현 확인용 pilot입니다. QA 10 개라 통계적 일반화보다 method behavior 확인에 의미가 있습니다.

특히 문서는 희귀 전문 용어와 source precision이 중요하므로 BM25와 RAPTOR summary node는 상보적으로 해석해야 합니다.